Exaclement comme un tube simple Mais : ouverture d'un tube par un nom Plau: greation des réchtes vous entre pro supcial de la character de creation de la cr Hérite : les gérantes, les signaux ignorés et bloqué Vide : les signaux en attente 340 e Dans un prc Designe un fich ouvert Sert à la manipulation C'est un entier tout simple (in Write prog to work together Write prog to handle text streams, because that is a universal interface Visition—, segacilizadi procision porting de incobe annien Min des foto segorines Min de communication interprocibios, sockets...) Min de communication interprocibios, sockets...) Min de communication interprocibios, sockets...) Types de sys de for struct sockaddr_un addr; addr.sum_family = AF_UNIX; strncpv(addr.sum_path, "sock", siz nication entre app informatiques est un domaine bien La com large Un signal reçu et géré peut interrompre int res = connect(sock, (struct sockaddr*)&a if(res==-1) { perror("connect"); exit(1); } 0 : entrée standard 1 : sortie standard 1 : sortie standard 2 : sortie standard pour les msg d'err C'est des conventions de l'esp user : le Chacun les traite à sa façon Un seul prc a les données à la fois onnées partagées entre prc (shared m Nbux types existent Wikipédia en liste et compare une centaine char buf(6); read(sock, buf, 6); avinef("read Tale", buf) ast-ce qui se passe alors. Pro dars syscali attragé, gérante invoquée; gérante terminée Sypala tarraite de force (interrompu) Rebuume EINTR (si pas commencé) O un atre val si travali partillement réalisé Sauf si S.A. RESTART dans su, flag de signatio Mais pas pour tous les syscalis RTEM pour les détais Observation of the Control of the Co Willipida en liste et compare une certaine Mission en selections. A des sys etion organisations. A dies sys etion organisations. Contrible se l'evolution, mais aussi syndrome NIH A die bezonis specifiques des users Contrible se l'evolution, mais aussi syndrome NIH A die bezonis specifiques des users Contrible des contraintes physiques des périphiriques et des ord Champs de bits Contrible se présentation des domnées sur disque Champs de bits Dans les se se de domnées Dans les se sindisparanes (misful) Dans les se sindisparanes (misful) Lincia les services (misful) Conness partagess erire (p.c.) (sared memory) Connéss communes Accès et modif non exclusives Dessions : à quel modèle correspond Tube shell «! »: 1 2 threads et une struc de données dans le tas Fich dans - "Documents : 2 Base de données : 2 us. n(2) bloque jusqu'à avoir un lecteur et un écrivair include "machins.h" st main(int argc, char **argr) Char Cellist, 1, **vurus) Filincipie Exicute CMD dars un pro indépendant Où la sorte standard de CMD est redingée dans un tube Substitue l'agr (CMD) par le chemin du tube Cualqu'un quo courriace chemin sear connecté au tube Deair incligémentations Pleado thic fort tubes (proc(S)) si dispo Tube nommé sinon int sock = socket(AF_UNIX, SOCK_STREAM, 0) struct sockaddr_um addr; addr.sum_family = AF_USIX; struccv(addr.sum_path, "sock", sizeof(addr.sum_path Fich Terminaison de prc : exit(2) et wait(2) Signaux : signal(7); y compris sial(1) (410) Tubes (pire) : pipe(7); y compris « 1 » et tu Sockets UNIX : unix(7) (430) Sockets classiques (TCP, UDP...): socket Mém partagée: shm_overview(7) Plus qualques autres sigwaitinfo(2), sigtimedwait(2), sigsuspend Attend des signaux Note : Bloquer les signaux avant avec sign Dans les SE Dans les outils annexes (mkds(8), fsck(8)...) C'est compliqué, surtout si le format n'est pas documenté Besoin maximal de fiabilité : ne pas manger les données Découp int res = bind(sock, (struct socksddr *) #addr, if (res == -1) { perror("bind"); exit(1); } listen(sock, SOMAECOSS); int cli = accept(sock, NVLL, NVL write(cli, "Norld", 6); char buf(6); read(cli, buf, 6); prinsf("requ: Xe\n", buf); close(cli); Dèc Blocs de taille fixe, configurable, ou variable (ça dé Découpe tout l'esp disque Simplifie la gestion : blocs au lieu d'octets Tout est des blocs ensuite : données ou gestion Crée un descripteur de fich spécial Permet de gérer les signaux comme des évèn (« tout est fich » Attendre un signal avec poll(2), select(2)... POSIX sockets alias BSD sockets alias Berkeley Pour la communication réseau entre prc socket(1 API offerte par le SE → Plus quelques autres → Plus tous ceux spécifiques à d'autres sys → Plus tous ceux « applicatifs » basés sur ces pri (remote proedure call), bus logiciels... Cognitation Interes: 3 TD. Tables des describlers l'une par grot - the entrée par descripter, propre à chacun des pro du sys - Porties un un chouvert (-- 1707) - TBO. Tables des faits ouverts (poblate) - the entrée par demande d'ouverts d'un fich - the copen ou create ou autre - Porties un un mode en main (-- TIM*) - TBM. Table des insides en miles (globale) - TBM. Table des insides en miles (globale) - Synchronise avec les inodes sur disque - Cau confiert un opteur. - Mot sur les fich ou sur les fich ou Sies fich ne sont pas exclusifs à un proi Les pro peuvent utiliser les fich pour communique Les pro peuvent utiliser les fich pour communique Commitée Fich de données et autres doc (explicitée à l'user) Fich hemp pour passer des données (compilation. Fich spéciaux pour initier un autre type de comm (etc.) Les octets écrits au bout en écr (write Sont lisibles dans l'ordre au bout en le Nb max d'inodes Taille max d'un fich Nb d'entrées max par rép Taille max du volume... Un client après l'autre Boucle principale de accept(1) Traite Chq client entièrement, et dans l'ordre • pipe(7) pour les détails rocessus Tube Process Type FAT32 NTFS Prob. Traitments courts seulement Un clief peut bloque les autres Géneral Une liste de clients connocides Boucle principles avec un select,²) ou polit,² Boucle principles avec un select,²2 ou polit,² Boucle principles avec un select,²2 ou polit,² Soucle principles avec un select,²2 ou polit,² on sarveille le sociée d'écode - chiscus des dériets connecte autres de la connecte de la connecte de la connecte de la connecte d'autre touge on or lates administré Prob. messages courts seulement, pas adopté aux cas con Descripteurs de fich Pour un prc, un bout de tube est un descripteur Chq extrémité se manipule comme fich ouvert rei API commune Diff et nheux protocoles Diff types de communication Diff types de communication API compris propriétaires ou désuets API compris propriétaires ou désuets API compris pesifiques à Che protocole EL ADI variante Unix API comprises avec d'éfauts de conception hists API comprises avec d'éfauts de conception hists Info : /proc/sys/fs/inode-nr nb d'inodes en mém /proc/sys/fs/file-nr nb d'inodes ouverts distincts commandes Socket ré Obj primaire : faire communiquer des app sur des ordi distincts Peut aussi être utilisé pour des app sur une mm mach Majoritairement pour du clients-serveur close(2), dup2(2), poll(2), etc. • Mais pas Iseek(2) (err ESPIPE) Show. Prob : messages courts www. Multitread Unit fread principal docust On lance un nouveau thread par client (au pool de threads) Prob : programmation multithread Show the s Sueau noyau Esp mêm du SE L'esp et son accès sont gérés par le SE Capacité limitée (64ko défaut actuel sous Linux) Mais ce n'est pas un prob Contraintes internes au type de sys Tailles en octets de valeurs ruméniques Param configurés par l'user Lors du formalage; mež/58(g), mids(8)... Limites d'implémentations Le format peut stoker plus, mais les logiciels ne peu. Combinaisons directes et indirectes de tout ca ntages Le SE peut optimiser l'efficacité du traitemen Ex : client/serveur X (X(7)) PIDIfd le fich (ou autre) associé au descripte. PIDIfdinfo des info sur le fich ouvert prox/PDIddric des info sur le fich ouvert Table des inches en melm - scale per 1 TML (E. SES minimum les accidentes automorphisme Des accidentes automorphisme Des accidentes accidentes accidentes Des accidentes accidentes Des accidentes accidentes Des accidentes accidentes Des accidentes accidentes punctificiones sur disque punctificiones caches ibbere l'exp des caches Diddricentes accidentes Propueste lette accidentes accidentes Propueste lette accidentes accidentes Propuestes l'experiences accidentes Diddricentes accidentes Diddricentes accidentes Caches nogue Caches nogue Caches nogue TRO : Table de TTO : TT API complexe area community societies A Societ » devenu un terme générique Autres langages et sys ont leur propre API de sor API souvent proche (concepts et vocabulaire), pr Types Support de comm de haut niveau Majoritairement applicatif (en esp user) Permet de faire communiquer des app via des obj des envois de msg acovent pour le réseau (ex. CORBA) Exemple: D-BUS iore Un pro principal écoute Un sous-pro (fork(2)) par client (ou pool de pro) Prob : lourd et isolation des clients Avantage : robuste et isolation des clients Création : syscall pipe(2) « Retourne » deux descripteurs de fich 3 dimensions principales Novesses variations spécifiques Granularità Flux d'octets (sterem) Messages (disagram, packet) Connectività Connectività Connectività Connectività Messages (disagram, packet) Connectività Messa recomme o oeur descripieus int 154[2]: pipe(15s]; fds[0] le bout en lect fds[1] le bout en écr Astuce mnémotech : 0=stdin 1= Tubes nommés Création : mkfifo(1) et mkfifo(3) National per totale et solution des citents Domnées spécifiques supp aux me grand Alias « messages de contrôle » (cmsg) Contens sémantique et époségue . Mais o qui est poss est spécifique à chiq domaine recomsg(2) et sendme(2) pour les utiliser comsg(3) pur yeacht . Promise de la control de cker les données des fich (gros et petit) Stocker les données des fich (gros e Stocker les métadonnées (y compris Stocker les entrées des répertoires Gérer l'esp libre (inodes et blocs) Plus avancés indle: D-BUS Uitlisé dans les bureaux graphiques Unix modernes Un démon + clients exposent&utilisent services&ob, Biblio utilisables par les prog Démon et biblio utilisent des primitives sys pour fair comm, de sync et de protection Plus avancés Chiffrement et compression Journalisation Instantanés (snapshots) et branches Déduplication Multi-volumes, RAID... Somme de contrôle (checksum) Correction d'err faut un protocole de comm Mouens de comm (données, struc de do hois[1] Processus Moyens de comm (données, struc de échanger et accéder Primitives d'accès et de protection Mécanismes de sync Attention aux prob standards interblo narireseau principalement) Fiable : service garanti, obligation de résultat Risques de sacrifices : moins de débit et plus de late The : Table Une entrée par le open(2) (ou autre) effectué Confient le mode d'ouverture (lect, écr...) Confient le curseur lect-écr (éventuel) dans le fich Un mm fich paut être manipule indépendamment pe Iseek(2) permet de déplacer le curseur lect-écr Descripte Lillisable dans les sockets du domaine Unix SCM_RIGHTS passe des fich ouverts L'émetteur attache des descripteurs de fich Le sys crée des descripteurs dans le prc récep C'est pas forcément les mm num de descripte Non fiable : service au mieux, obligation de moyen Risques de pertes de données, modif du contenu, pertes de l'ordr duplications Allocation et al sation contigué Les bloos de données d'un fich sont contigus Ex: ISO 9660 (CDs) Naïl: en général, la taille des fich est inconnue et e ablon chainée Qui s'en charg Fournit des syscall pour IPC ± riches et complexes Régles spécifiques au cas par cas Impose un protocole mais gar antit cetaines propriétés Qui s'en charge ? Le proUtilise les primitives sys pour implémenter ses propres prosoo Beed_Dymenu outpoon we cause netwo held Sacinde-Centric hab Sacinde-Centric hab Sacinde-Centric hab Sacinde-Centric hab int nain(roid) { int nain(roid) { int four = creat("halle", ode6); creat(four = nagout, strim(nagout)); vrite(in = nagout, strim(nagout)); close(fdout); close(fdin); return 0; } Un tube est créé par un pro Mais est globel au sys Partage de tube par fork. Les descripteurs de fich sont copiés Les bouts de tubes sont partagés Mais c'est les mm fich ouverts socketpair(2) crée deux sockets con Ressemble fortement à pipe(2) Mais bidirectionnel ! Msq poss (pas slm flux d'octets) ! Un bloc de données connaît l'adr du suivant Ex: FAT recv(z), recvfrom(z), recvmsg(z) reception (2), shutdown(z) fermeture cckopt(z), getsockopt(z), ioctl(z) configuration cckname(z), getpeername(z) identification (z) bien évidement interdits (err ESPIPE) Ex:FAT Prob: accès direct lent ((seek(2)) Allocation indexée Un fich connaît la liste de ses blocs de données Prob: comment stocker des gros fich ? Difficile av Allocat unications. Entre parent et enfant Le parent crée le tube L'enfant hérite les descript Entre deux enfants Le parent crée le tube Les anfants Le parent crée le tube Les enfants héritent les des app Prend en cpt les limites et caractéristiques des IPC utilisée Est libre d'implémenter tout ce qu'il veut per-dessus ⇒ les IPC sys sont des outils pour bâtir sa sol de coop 500 _ SYNCHRONISATION Des éléments logiciels (voire matériels) Sont capables de s'exécuter en « mm temps » Indépendamment du moment ou de l'ordre de Sans tout briser Abstraient les IPC sys Abstraient les IPC sys Offrent des fctionnalités et protocoles clé en main Ex : requête https en JavaScript, JEE, D-Bus... Il est normal de les utiliser quand c'est adapté Pleurs vers les blocs de données Pleur direct : contient l'adr d'un bloc de données Pleur indirect : contient l'adr d'un bloc contenant Pleur indirect double : contient l'adr d'un bloc cont omaine = famille de protocoles • AF_INET pour IPv4 (ip/7)) ou AF_INET6 pour IPv6 (ipv6(7)) Un seuf fich hello Deux ouverfures (distinctes) Deux descripteurs United Section Sec és[1] Processus pire Ca veut dire quoi en « mm temps »? Pr Quel rapport avec les SE ? Prochains d me d'interruption logicielle ndirects... on : Comment déterminer où s'arrêtent les données ? O Analogie avec les interruptions matérielles Permet d'expédier à un prc une info urgente Comment s'assurer de la cohérence d'un fich si plars pro peuven écrire en mm temps ? Au programmeur d'en assurer. oncurrence In élément logiciel s'exécute avant que les autres finissent 'ordre des exec de chacun est variable Adressage index à de ext2.0 real la table des incodes real la table des incodes 19 ya 15 planur de blocs: 12 sont des plears directs 1 est indirect 1 est indirect 1 est indirect double 1 est indirect double 1 est indirect double 1 est indirect double 1 est indirect prejeuent seur 22 bits (46) and 1,0 auther sont feet indirect seur 22 bits (46) and 1,0 auther sont feet indirect seur 22 bits (46) and 1,0 auther sont feet indirect seur 22 bits (47) but held a belough in condesse y 27 feet in 25 bits (47) but held a belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in condesse y 27 feet in 25 bits (47) but held belough in 25 bits (47) Un signal est envoyé Il sera reçu et traité au n Pourrait-on faire communiquer des prc via un fich co Oui, mais c'est pénible à synchroniser. Protocole particulier si plus d'un pour un domaine et un type 0 = protocole par défaut Present particular : - In the descriptions of associale au pro - born particular in a construction of the Invocation de suar progr. Parallélisme Exec physiquement au mm moment Architectures multipro et multicoeurs Voire sys distribués Mais rendu là on a d'autres difficultés en plus ecture S'il y a des données dans le tube signal () estionnaire de signaux par pro Chq prog gère toutefois les signaux comme il veut La sémantique doit être documentée dans le prog (man) En particulier si elle diverge du catalogue communication efficace via la mér Zones de mém gérées par le SE Pro lisent/écrivent dans des descri Anonymes ou nommés Syno D'un fich si tous ses blocs sont pleins r re D'un fich si la taille est codée sur 32 bits ? D'un volume si tous les blocs sont utilisés read it le max u com. Si le tube ast vide Si un écrivain existe : read bloque Si aucun écrivain : read retourne 0 (fin de tube) Suspects: Deux threads t1 et t2 d'un mm pro Victime: Une variable globale i partagée Code du crime, exècuté par les deux threads: Ultra November 1 Steets Letters On stocke 2 rise plattif que tous les bloos de la saile et al, buffs, rifs... Prob. of allocation configue Statut de connelse arbor eccente aquillirée Adaptée au sy et 6 net he base domnées bifs, rifs, rifs, etc. Prob. rore au déalis algorithmiques Sync Lect si vide: bloquée ou 0 si aucun écrivair Ecrivain SIGPIPE s' aucun lecteur ou bloqué si pleir acce avec les tubes Ultiliser IPAI des societs POSIX Bidractionnel Connecté ou non connecté Flux d'octets ou messages SIGNIT Ctrl C génère ce signal dont le comportement par défaut est d'arrêter le pro d'arrêter le pro SIGSEV Une err de seg provoque l'expédition de ce signal au pro fautif Sil y a aucun lecteur Sil y a aucun lecteur Signal SIGPIPE envoyé (par défaut, termine le pro) """ nige) La table des descripteurs est prése sorties standard) i++; Obestle prob? ; assembleur x86 ; pep8 ; movq i(%rip), %eax; LDA i.d; addq \$1, %eax ; ADDA i.d; movq %eax, i(%rip); STA i.d; Cmd kill(1). Envoie signal SIGTERM par riéfaut Lecteur ou va trop vitie Bloque jusqu'à ce qu'un écrivain écrive Ou plus données ni d'écrivain (read retourn Écrivain ou va trop vitie Bloque jusqu'à ce qu'un lecteur consomme Ou que plus de lecteurs (SIOPIPE) Questions Syscal kill(2) Question: kill est souvent une cmd interne du sh Adi Désignation d'un socket existant ou potentiel Struct C semi-opaques, fragiles et contraignantes (berk!) Détails spécifiques à chq domaine Ex. chez (P: adr IP + num de port Structures d'adr. hread 1 Thread 2 i A(t1) A(t2) DA i,d our cho catégorie de signal, un pro peut juoi ce n'est pas sysmétrique ? (0 vs. SIGPIPE) Les 2 bouts Accepter le comportement En général, arrêt du prc Ignorer le signal (pas tous) Gérer le signal (pas tous) on des permissions LDA i,d ADDA 1,i STA i,d Incohérences données et métadonnées Sol : écrire en deux temps On écrit les données dans un journal Quand le journal est écrit, on recopie dans le dis Prob de coût : écr plus chère (copie intermédiaire Seuls les prc d'un mm user pe Et root (RTFM pour les détails Pas de kill sur le prc du voisin Opérations atomiques PIPE_BUF (512 min, 4096 chez Linux) write écrits PIPE_BUF cottels (ou moins) Abmiquement = écrit d'un coup sans qui sintrelacent Entrées-sorties not bloquantes Flag O_NONBLOCK poss (via find(2)) On jette les données du journal (tant pis!) → On caste allègrement entre des pteurs de ces types (berk!) vrite(1, buf, len); return 0; The second section is a second to desire the second second section. Description second section is secretary as a second second section is second section in the second section in the second section is section in the second section in the second section is section in the second section in the second section is section in the second section in the second section is section in the section in the second section is section in the section in the section is section in the section in the section is section in the section in the section in the section is section in the section in the section is section in the section in the section in the section is section in the section in the section is section in the section in the section in the section is section in the section in the section in the section is section in the section in the section in the section is section in the section in the section in the section is section in the section in the section in the section is section in the section in the section in the section is section in the section in the section in the section in the section is section in the secti Sockaddr du domaine Ur truct sockaddr_un { sa_family_t sun_family; /* AF_UNIX * char sun_path[108]; /* Chemin */ LDA i,d ADDA 1,i STA i,d Le journal est complet et cohé On termine l'écr depuis le journalisation Nbux détails spécifiques Les règles de sync et d'atomicité ch RTFM Bonjonde! Noux détails spécinque. Noux détails spécinque. Configurations poss Question : Journaliser seulement les rempromis ? Oui, car c'est la partie la); Attention, sun_path a une taille max (berk!) non port. Fich spécial socket Ullisé pour « nommer » les socket* Type « s » sedon is «! Créé par bind(2) Supprimé par unriink(2) open(2) échoue (ENXIO) ur mouldiou! Concurrence vs parallélisme Monopro Spéc Flag O CLOEXEC O CLOEXEC flag de open(2) (et autres syscalls) Le descripteur sera automatiquement fermé lors d'un e → Évite la futte de descripteurs ou gaspillage de ress munipro Prob quand changement de con Multipro Sestion classique des signaux en deucerire la fct gérante (en C classique) Signature simple void foc(int sig) (pour sa_handler) Ou complète void ber(int sig, siginfo_t* info, void* ucbt) (pou include Cunistd.h> at main(void) { int embois[2]; char buf; pipe (embois); read(embois[0], &buf, 1); Multipro Probabilistic de prob bien plus grande Débogges difficile : syndrome s'chez moi ça march/venbezdes malificile : syndrome s'chez moi ça march/venbezdes malificile instruction e us des \$1.4(% rip) > Onagement de prob Onagement de condiset à want ou après l'ins Multipro. Tips prob de concurrence I instruction, mais Pitras rydes RAM partagle Oborne et choference mém Ouel rappe Aches Linux One(2) permet de décider quoi partager ou cloner CLONE_FILES la table des descripteurs CLONE_FS des info liées au sys de fich, dont o lion : Comment se bloquer à deux ? On crée un pipe et on Descripteurs synonymes Deux descripteurs d'un mm prc peuvent pointer une mn dans la table des fich ouverts ieuse(2) suspend l'éxecution jusqu'à un signa itrsignal(3) et psignal(3) pour le texte des sign Instantanés : on peut garder d Branches : des versions peuve In seul lecteur et un seul écrivain « «Tjrs par deux ils vont, ni plus, ni moins » – Yoda ermer les bouts inutiles sization. nclude catdlib.b> nclude catdlib.b> nclude catdlib.b> nclude catdlib.b> nclude catdlib.b> nclude catglanl.b> include catglanl.b> include catglanl.b> id gare(int sig) { print("Aequ %d: %a\n", sig, streignal(sig)) exit(1); Syscalls dup2(2) (et dup(2)) Quel est l'intérêt ? Traitement d'évén logiciels et matériels Des évén fondamentalement imprévir Interruptions matérielles Syscals de prc (si vrai parallélisme) Performance des SE Chq prc Est autonome Vit isolé dans son propre esp mém Redéfinir les entrées et sorties standard Redirection de fich Laisser des bouts inufiles Laisser des bouts trainer caus e des prob de sync Souvent : lecteur bloqué, car un bout d'écrivain re Pisrs écrivains et dou lecteurs ? O'act book——— Communication par tube (pour plus tard) Communication par tube (pour plus tard) Counting: Quelle est la diff entre dupliquer un descripteur et cuvrir rétois un fich ? Dupliquer: On peut crèer un nutre. rop restrictif Besoin de collab, comm et de coop Prc diff opèrent ens vers un mm obj communication interpro Performance de SE : Exploitation dos possibilités de concurrence et parallélisme Traitements paralléles internes : threads sys Préempton sys : les noyaux modernes sont préemptis Une approche un seu pre en sys à la fois » fonctionn tes limitante côté performance Offre de mécanismes de sync pour les pre C'est techment poss, mais: Bien comprendre les règles de sync et d'ato Les clients doivent être coopératifs Msg de talle fixe aide bcp Utiliser un autre IPC, c'est souvent moins riss IPC (interprocess communication) Mécanismes du SE Parfois offerts par biblio et démons nt main(void) { struct stantion action; stantion action stantion stantion stantion stantion stantion stantion action; stantion action action; stantion action; Partos delle pur biblio d'denine (ep. user) Condestion isseme App corque à la base multifèreads et multipre Ex: navaglants modeme — Objecties performance, asynchrovisme, siodation. Diogration profrontance, asynchrovisme, siodation. Diogration profrontance asynchrovisme, siodation. Ex: la plupat de app qui respectent un protocole Ex: la plupat de app reseaux — Atlantion à the robuste — App marginal des domines, produite (ou non) par d'autres app Ex: cournierregistrer, tubes shell, etc. — Philosophie #include < unistd.h> #include < fcntl.h> #include < stdio.h> bind(int fd, const struct socka Expose une « adr » publique Ussimite Pas d'interaction entre entités logicielles → Facile mais ca n'arrive pas souvent int main(void) { int fd = creat("sortie", 0666); dup2(fd, 1); printf("Hello World!\n"); return 0; Des ress partagées existent Des ress partagées existent On veut s'assurer de leur disp C'est un travail pour le SE Coopérative Pour ignorer un signal, mettre SIG, ING dans a hander Pour lacido par défaut, metre SIG, IPG dans a hander Pour lacido par défaut, metre SIG, IPF, dans a hande les signaux d'une modégoirer sos opies emplée de un ma signal pout activer une seule invocation de un manuel pour la cuther une seule invocation programma. Pour la manuel partie la manque de signal pour la companya de la proposition au maux les signals que la signal programma. Pour manuel de la manque de signal un la companya de signal un Retourne un nouveau socket, connecté directement au client On a donc un socket d'écoute + un socket par client connect Des sys offrent des tubes bidrectionnels (pas portable !) Utiliser un autre IPC, c'est souvent plus simple Inux et pseud. Client copérative Des éléments logiciels coopèrent La concurrence fait partie du programme C'est des modéles de programmation sp → Le SE offre des services de sync → Mais il y a aussi des ress à gérer #include<unistd.h> #include<fcntl.h> #include<stdio.h> Make each prog do one thing well. To do a new job, build afresh Ouvrir un pseudo fich tube de /proc/PID/id est poss Le mode d'ouverture indique quel bout du tube on obtient Permet d'ajouter des lecteurs et des écrivains moner envir prug us une tring weil. I do de new job, build affesh rather than complicate old prog by adding new « features ». Expect the output of every prog to become the input to another, as yet unknown, prog. Don't clutter output with extraneous info. Avoid shingerify columnar or binary input formats. Don't insist on interactive inout. int main(void) { int fd = open("hello", O RDONLY): Situation où le résultat est diff Dépendement Situation oil le résultat est diff Dépardament du moment ou del ordre d'exec -> Cest souvent problematique Situation diff Situation d'existe de sécurité Contra moment Particularie d'existe de sécurité Ordre at moment Particularie d'existe de sécurité Contra et moment Particularie d'existe de l'existe d'existe d'exis imites des tubes simples Via héritage des pro En créant le tube d'av samagenity columnar or binary input formats. Don't insist on interactive input. Design and build software, even operating sys, to be tried early, ideally within weeks. Don't hesitate to throw away the clumsy part and rebuild them. —nue tabe d'avance → Communication entre pre indépendants difficil Principe des tables normals — Les tables normals ne sont pas hérités, mais — Donc plus besoin d'hériter des descripteus N de crète la tabe d'avance | Paractérissiques* and rebuild them. Use tools in preference to unskilled help to lighten a progran task, even if you have to detour to build the tools and expect throw some of them out after you've finished using them. aass Partagent : les gérantes, les signaux ignorés Copie : les signaux bloqués (masque des signaux) Fctionnalités fines existent pthread_kill(3), pthread Certains signaux en attente peuvent être partagés (Un descripteur est un entier, partager 4 n'avance à ri Le noyau doit être impliqué Via sockets Unix Write prog that do one thing and do it well

Problém Refraitbancaire if (montant < solde) { solde =- montant; return montant; } else { inc(void) { On manipule sans verrous Oirectement fonction built-in gcc atomic_add_fetch(&i, 1, __ATOMIC_RELAXED) return 0; // Solde insuffisant > Suppression d'un maillon d'une liste doublement chaînée if (current->next != NULL) current->next->prev = current->prev; if (current->rev != NULL) current->prev != current->next; Sections critiques plus mplémente un verrou atomique instructions e test and set », « compare and exchange »... x66 xxdp, lock cmpxdp... goc: __atomic best end ... __aton eux threads paralléles fort malloc(3) Affibuer correctement une zone mêm distincte Ne pas corrompre les struc internes du tas eux pro lisent écrivent en mm temps dans un tube Affibuer des octés diff (sans en perdre) Ne pas corrompre les struc internes du tube ésoudre un chemin (pash resoft). Alors qu'un pro renomme ou déplace des réperi id inc(void) { while(atomic_flag_test_and_set(&flag)) {} +; // on manipule comic_flag_clear(&flag); Éviter les accès simultanés qui rendra Garantir une certaine équité Maintenir la performance Éviter que le sys ne se bloque Atte while (...) {}, infinite : le temps que les choses se libèr • Quand ça fonctionne, ça reste inefficace → Ça gaspille du temps prc à activement rien faire y Ca gaspille du temps μις stions : : ideux autres propositions : : : ''' · ' / ' / ' sched_yield(); }† --- 510 - SECTION CRITIQUI Les threads (et prc) while (...) { sleep(1); } Pourquoi c'est pas vrm bop mieux ? Gourmant. Boucle infinie. Y a-t-il des cas où c'est mm pire que la proposition initiale ? No ros sched, yield(2) force un appel à l'ordonnanceur pour uellement donner le prc à un autre thread. blectifs Contrôler les situations de compétition Prévenir la corruption de ress partagées Indépendamment du type de ress Rester efficace titis Contrôler les situations de compétition Prévenir la corruption de ress partagées Indépendamment du type de Rester efficace Sc = Zone de code Zone de code = morceau de prog Altention, pas forciement configuê Sc = Zone d'exclusiviti Exécuté que par un seul thread* max à la fois Um aniquie une ress potentiellement partagle On protège une ress en contraignant l'exec duct Approches purement algorithmiques limitées Instructions machine spécifiques peu portabl oette ress "Sans perte de généralité, on utilise « threads », mais ça s'applique pare aux pro monothread, táches noyau ou toute autre entité louiniallo « — d'œec.

 Bricolage bas riveau
Potentiellement inefficace (spiniook)
Scil 'Lia nouveau riveau d'indirection'
Note of demandre au 55 de nous lorsque les ress sort dispo (\$20)
Languages, biblio et 55 à la rescousse
Langu v arrive à la main, ma

 Nest pas nécessairement actif à 100%.
 I peut faire des syscalls bloquarts (et devenir bloqué)
 I peut être préempté (et devenir prét)
Sentireir
 Tant qu'un thread n'est pas sorti
 Aucun autre thread ne peut y rentrer only arrive a la miant, mias

Cest compliqué

Cest bas niveau

Cest doubleur d'un point de vue performance (atte
Pout-on faire miseur.?

Le SE est capable de se débrouiller

Qu'en est-il des pro et threads ?

Les 4 règles des 5

1) Au max, un seul thread à la fois en sc
2) Pas de supposition sur la vitesse ou le nb de threads
3) Un thread hors sc ne bloque pas les autres
4) Pas d'attente infinie pour entrer en sc (famine)
Sol d' SE, biblio et langages
 Ils fournissent des outils
 → Services et des modèles de sync clé en main

long i; // ressource partagée int flag; // booléen protegant la ressource Les développeurs peuvent les utilise s spécialisés La programmation concurrente reste comples
 Ces outils ne suppriment pas les difficultés fo
 Au mieux, ils les transforment et les déplacer

stion Lesquelles des 4 règles sont violées ? 1) Trouvez un scénario (ordonnancement) où ça ne fo

extern int nb; // nombre de threads int tour; // ā qui c'est le tour?

7 Question : Lesquelles des 4 règles sont violées ?

Pour deux threads seulement

int flag[2]; // qui est interessé int tour; // à qui le tour (si

 Se généralise à un nb quelconque de thr Bathuction (ou und cation) destinée:

Aux pro
Force les écr et lect du bon côté de la barrière
Au compliateurs C
Foréviert les optimisations qui changent la sémantique
Doût non étigligable

Cott non négligeable
 Exemplés
 Instruction mience en x86
 Pas de mot clé C standard
 atonic, firread finere de C11 statamic h
 Extension C de goc : __atomic_firead_fence
 (et le plus ancien __sync_synchronize)

Intome qu'une modit indépendante est poss Et qu'il doit éviter des optimisations Par défaut, le compilateur n'est pas conservateur ! Les opt de compilation changent le comportement du code and le compilateur voit

On peut juste implémenter une boucle infinie

Si x est viclatile
On doit telser x à Chq tour, « au cas où... »
Sonne ou mauvaise chose?

La présence de volatile dans du code est souvent douteus e
Son utilisation ne permet pas magiquement de résoudre les

Mot clé C volatile
 Déclare uno de-

Si x n'est pas volatile
 On peut juste implément

concurrence Son coût est non négligeable volatile considered harmful

volatile int flag[2]; // qui est interess volatile int tour; // å qui le tour ?

Masquer les interruptions matel l'horloge) Verrouiller le bus (en multipro)

Grain grossier Couteux Seul le noyau peut faire ça (ok pour lui, mais pas pour les prc)

C11 _Atomic et stdatomic.h, extent
 Permet des manipulations atomique Indivisible pour l'observateur Exemple : incrément atomique.

Déclare une donnée comme multi-un autre thread)

Pour le compilateur seulement

Informe qu'une modif in léanaige.

void inc(int k) { // k c'est moi, !k c'est l'autre
flag[k] = i; // on veut estrer
tour = !k; // on est poli
while (flag[!k] &k tour == !k) { } // attente
i++; // on mainpule
flag[k] = 0; // on m'en veut plus

An illimitat, is not artificion to the objuscent.

Base

Rappel 1 es apositio coater cher

Une partie des mécaraismes est faite en esp user

-> Langages et biblio

Une autre partie en mode noyau, par le SE

-> ordonancement et états d'excé des pro

Concrétement

Implémentés avec les tech primitives précidenter

Garantissent l'efficacité et la fabilité

-> Garantissent l'efficacité et la fabilité

-> Biennemat état à programmation concurrenter une

Le SE gère le cycle de vie des threads Sol à l'attente activa

à l'attente active
Un thread veut entrer en sc déjà occupée
On le bloque (passage de l'état actif à bloqué)
On appelle l'ordonnanceur
Un thread sont d'une sc
Un autre thread était en attente ?
On le réveille (passage à l'état prét)
Et on appelle l'ordonnanceur

Ex un appelle l'ordonnanceur

Le tout de façon performante !

Lestout de façon performante !

Leston : Quels sont les cas où l'attente active est préférable à un hangement de contact d' Lorsque le changement de contact de l'active de

Mutex (ou verrou, lock), de mutual exclusio
 Concept général de verrouillage de sc
 Mais détails spécifiques en fonction du contexte (SE. biblio, langage

Mars detains specifiques en forcion o de programmation)
 Opérations générales
 Verrouiller ; que entre ou çu attend
 Déverrouiller ; qu débloque les autres
 Tenter : çu entre ou çu échoue

 Actif (spinlock) ou bloquante (passage à l'état bloqué)
 Rapide (un booléen), récursif (un compteur), avec détection d'err
 Muter othe Fourni de base chez pthre
 nthread mutey (cch/2) c

phread_mutex_trylock(3)...
phread_mutex_trylock(3)...
Limités aux threads d'un mm pro
RTFM pour les détails
include < pthread. h>

include < pthread. h > pthread.

ong 1; // Ressource partagée chread mutex t mut = PTHREAD MUTEX INITIALIZER id inc(void) {
pthread_nutex_lock(&nut); // on v

artagée / Ressource partagée
m_t sem;
init(void) { // initialisation
t(&sem, 0, 1); // initialise à 1

idée : empêcher le changement de contexte

id inc(void) (
sem_wait(&sem); // verrouillage
i++; // on manipule
sem_post(&sem); // dévérouillag

Moniteur (sous-prog + mutex implicite + variable Barrière Verrou lect-écr RCU (read-copy-update) : tech sans verrouillage Struc de données parallèles clé en main

Opérations atomiques (C11)... ont des outils et abstractions de programmation Bloque un prc jusqu'à un réveil expli Bas niveau et délicat

Sert aux biblio pour implér

_GNU_SOURCE <sys/syscall.h> <unistd.h> inux/futex.h>

lotvo-c = capxobg(&flag, v, ... != 0) { (c != 2) c = xchg(&flag, 2); ile (c != 0) { syscall(878_futex, &flag, FUTEX_V) c = xchg(&flag, 2);

Dearlinck Verrou fatal Étrainte fatale Embrasse mortelle

E nos découlant de l'allocation des res

Entiron dus formelle
 Un ens de pre sont en interblocage si Chq pro dans cet ens est en attente d'un évén que sim un autre pro de ce mm ens peut Akelencher — Tanencaum

non nue par un prc doit être libérée par lui Attente circulaire
Il doit y avoir un cycle dans les attentes d'évèn

rrincipe

Plisrs pro* sont bloqués entre eux et ne peuvent progress.
Sans perte de généralité on utilise « pro », mais ça s'applique preads, tâches noyau ou toute autre entité logicielle en cours d'

elques ress (au sens large) • Imprimante, CPU, Sémaphore, Sc (mutex)

declencher — Tanenbaum

L'évén peut-être est la libération d'une ress
cas d'intérbosage un pro ne peut

N confinuer son exec
Cer il est bloqué

N débloquer un autre pro
En libérant une ress
Cer il est bloqué
Cer il est bloqué
Cer il est bloqué

s 4 conditions nécess et suffisantes de l'int.
Exclusion mutuelle
La ress est soit dispo, soit assignée
Détention mutiple (hold and wait)
Un pro qui détient une ress peut en den
Pas de réquisition

Graphe biparti orienté

S T U

(b) (c)
(a) Ress R assignée au prc A
(b) Prc B demande et attend S
(c) C et D sont en interblocage

rincipe

Prétendre que le prob n'existe pas aisonnable si

Modélisation et analyses
 Tester
 Tester
 Modélisation et analyses
 Tester
 Tester
 Tester
 Modélisation et analyses
 Tester
 Tester
 Tester
 Tester
 Tester
 Tester
 Tester

vantage • Facile à comprendre, à mettre en œuvre

Echec du verrouillage
 Retirer de force une ress
 Restauration d'un état antérieur (rollback)
 Éliminer un pro

Annoips

Eliminer une condition de l'interblocage

iomnigies

Spooling: seul un prc a la ress

Ress toutes demandées d'un coup

Permettre la préemption

Ordonner les ress (donc les demandes)

→ Aucun n'est nécessairement faisable

incipe

Forcer l'ordonnanceur à faire le bon choix

C'est poss via des info supp

prc d'aller jusqu'au bout • Exécuter une allocation que si l'état qui en rés

in pratique.

Les SE actuels ignorent le prob pour les users
Seuls les SE critiques prennent éventuelleme prob

Un état est sûr s'il existe une s

Pas de solution ultime • Le coût et l'efficacité d'une tech

ynonymes

Starvation, Privation de ress
éficition

P2 s'exécute alors à nouveau

gmentation temporaire de priorité

P3 devrait passer avant P2
 Jusqu'à sortir de sa sc et libérer son mutex
 Pour pouvoir débloquer P1 le plus tôt poss lécessite la coopération du SE

Mesesta la coopération du SE

• Multar sare princis fatigue (PTHREAD PRIO PROTE La pro qui delbent le multer (P3) gagne en priorità

• Héritage de priorità (PTHREAD PRIO INVERTI)
La pro qui dettroi un multar (P1) ansiste automatiquem prope priorità au delantera du multar (P3). Restrocement delatione (ex Mirola)
Comme P3 délater la multar, il va peut-être gagner un pour peut-être sortir de sa so.

Définition
 Ung de prc partagent une ress
 Sans interblocage
 Certains prc n'obtiennent jamais la ress
 → Prob de l'attente infinie

rité stricte P1 > P2 > P3 3 prc de priorité stricte P1 > P2 > P3
 P3 arrive, s'exécute, demande et acquiert une ress R
 P2 arrive et s'exécute (préempte P3)
 P1 arrive, s'exécute (préempte P2), demande la ress

P2 passe devant tout le monde
 P1 termine dernier, c'était pourtant le plus prioritaire

Revoir la conception: est-ce normal que P3 puisse bloquer P1?
 Renforcement de la priorité

Principe

Vérifier si les pro sont en interblocage et les débloquer

Comment savoir s'il y a interblocage

Ouatre stratégies

Ignorer le prob

Détecter et résoudre

Prévenir le prob

Éviter dynamiquemen

Interblocages rares
 Autres solutions trop c

Les interblocages découlent de l'all rén liés aux ress
 Demander, Utiliser, Libérer la ress un pro demande une ress déjà prise
 Err, Attente, Attente temporisée

 unnees
 5 philosophes. Chacun pense ou mange (temps inconnu)
 5 fourchettes 5 plats de spaghettis 2 fourchettes sont néo

Prob

Comment faire tourner le sys sans bogue ?

Sans corruption, Sans famine, Sans interblocage

Efficacement

----- 600 - GESTION DE LA MÉMOIR Sépartir (allouer) la mém

Pour lui-mm

Filicacement et sans gaspiller

Controller et proteiger

Isoler la mém des pro

Chip ne a l'impression d'être seul

Offirir des services

Allocation dynamique

Mém partagée

Configuration de politiques

bric/2, mmay(2)

xchg(&flag, 0);
// on réveille un endormi, s'il y en a
syscall(SYS_futex, &flag, FUTEX_WAKE, 1, 0, 0, 0); Comprendre

Comment la mém est gérée par le SE (et le matériel)

Les possibilités offertes par la gestion moderne de la mém
Les algo liés à la gestion de la mém (utilisables dans d'autr

La bonne mém

• estrapide, grande, bon marché, non volatile, mais elle (encre)

En attendant i hierarchie de mém

• Caches prc, RAM, Disques Mém = grand tableau d'octets
 Accès matériel efficace (CPU ↔ RAM)
 Les pro vont et viennent
Dans la vrale vie ?

lans la vraie vie ?

Prc modernes (caches, pagination avancée, etc.)

Parallélisme et des architectures multiprc et multic

Architectures hétérogènes (NUMA, non uniform m

Adr explicites dans le code machine d'exe

Comment laroor Plass pro ?

Agrandssement de la mém allouée à un pro Que lién si on un a pas le place autour ?

Once de pro avec toxit?

Once de pro avec les places existents ?

Comment partager de la mêm entre pro ?

Comment partager de la mêm entre pro ?

Pourque on voudrait partager la mêm entre pro ?

Pourque on voudrait partager la mêm entre pro ?

Pourque on voudrait partager la mêm entre pro ?

Pourque on voudrait partager la mêm entre pro ?

Pourque on voudrait partager la mêm entre pro ? Pour

Solution : un nouveau nivea ne
Ne plus permettre aux pro de pointer directennies au
Les adr utilisées par les pro (pteurs, opérandes des instrumachine...) ne sont pas des adr absoluss en RAM

On convert les adr loigiques (des pro)
En adr physiques (en RAM)

ém physique (ou réelle).

• La RAM (un grand tableau d'octets)

Un numéro d'octet dans la RAM
Esp d'adressage physique (ou réal)

L'ensemble des adr physiques poss
 En général la taille du bus d'adr
 x86-64: actuellement = 48bits (256To

Memod Microsoft Control (1987) And Control (1987) A

MMU = memory management unit
Composarte matérielle, sur le micropro
Tradit automatiquement et efficacement
Adri logiques — adr physique
Les opérandes et pleurs sont en adr logique
Les opérandes et pleurs sont en adr logique
Ce qui circule sur le bus d'adr est en adr physique
— Cest transparent pour le logiciel

Accès direct du matériel (DMA) reste en adr physi

Charge:

A des param de tradución mém spécifiques

Cest sa « vue » personnelle de sa mém

Son sep d'atressage logique set automatiquement (MM
des morceaux de mém physique (ou à des fades CPU)
Chargements de conteste

La SE reconfigue de conteste

E param la traductión à celle du pro actif
Chargements de conteste a manifoliar

Control de conteste de con

Chq architecture matérielle est diffe et spécifiqu

Tech historique, très simple et très limitè
Deux registres spéciaux privilégiés : base
Traduction : physique = logique + base
Vérification : logique < limite

This process of the state of the state

imites

Mém relativement contiguë (sinon gaspillage)
Pas de partage mém entre pro
Pas de droits fins

Tech historique, complexe, et limitée
 Le CPU permet d'avoir PIsrs segments paramétrés

indépendamment Un segment = un bloc base-limite + droits spécifiques Résout les limites du base-limite Nexiste plus en x86-64 Sauf via deux registres spéciaux FS et GS

La solution à tous les prob ?

En yegy and SP AGESIZE) donne la teams use pergus yegy and la service and serv

 Numéro de page logique
 Adr dans la page (décalage From-1-Numéro de page logueux
Ard dans la page (décalage ou offset)

Exemple: page de étie, 48 bits d'adri logique = 36 bits (numéro de page logique) + 12 bits (décalage (2"12=46))

Traduction avec une table:
Associer numéro de page logique — numéro de page physique
Les associations sont stockées dans la table des pages

Taille: 4 octets
 Taille du décalage (en bits): 2 bits : 00, 01, 10, 11

**Table dockstagly (et in Is), 2 dis. 10, 01, 10, 11

Physikinus

• Acr 5 bits : # pages = 3 bits , offset = 2 bits

• Ego d'advessage (colets): 8 pages * 4 colets = 32 colets

• No de pages: 2*3 bits = 8 pages

Colique

• Acr 4 bits

• Ego d'advessage (colets): 2*4 bits = 16 colets

• No de pages: 2*2 bits = 4 pages

**No de pages: 2*2 bits = 4 pages

 Surcoût 0

 Accès du pre à une page virtuelle invalide
 MMU lève une faute CPU (faute de page)
 Le SE Page: 4 octets.. Adr physique: 5 bits. Adr logique: 4 bits

100116 0010 MOIS ME EN PILO (1)

Une table des pages par prc
 Le SE
 Configure et mainfient Chq table des pages
 Positionne la table du prc actif lors des chang contextes

Une seule table d'indirection ne passe pas à l'échelle

Paginatio
Découper l'adr logique en Plisrs morceaux
L'adr d'une table + un morceau donne un chemp dar
Chq champ d'une table indique
Soir l'adr de la table suivante à consulter
Soir qu'il n'y a pas de table suivante : faute CPU

Multi-niveau : pourqui
 L'esp d'adressage des prc est plein de vide
 Ne remplir que les tables intermédiaires nécessaires

Peut se combiner avec la segmentation (x86)

o Adr logique → adr linéaire → adr physiqu
Métadonnées supp

Exemption

4 niveaux: 4 tables + RAM finale

Un accès mém logique = 5 accès mém physique

Ohercher dans 4 tables + la domele finale

Plus 5 additions, 4 vérifications des droits, etc.

Les performances sont divisées par 5

Et ceci pour Chq accès à la mém

TLB et

TLB (translation lookaside buffer)

Cache les dernières traductions logiques → physiques

Cas idéal fréquent : 0 accès mém pour traduire

Cas pas idéal rare: faire toutes les indirections nécessai
Caches CPU

| S20 - MÉMOIR
| Offrir à Chq prc une mêm plus grande que celle dispo
| Utiliser le disque comme mêm supp
| Utiliser la pas forcément besoin d'être entièrement en

Cache le contenu de la RAM
 Évite l'accès à la RAM complète

principale

→ De façon transparente pour les pro Partitions et fich d'échanges

Mêmoire virti

Alias: swapping de prc
Quand la mêm est faible

Trouver un prc pas souvent actif

Copier toute sa mêm sur disque (

Puis libêrer la mêm du prc

→ La mêm n'est plus faible!

La mêm n'est plus faible!

Quand on doit confinuer l'exec du pro

 On recharge le pro en mêm (swap

 Quitte à swap out un autre pro poi

Paging (swapping de page)

Une page virtuelle peut être soit en mêm physique, sur le swap) ou invalide
 Si RAM est plaine: on sauve
 On descend des pages physiques vers le disque (page Si accès à une page virtuelle qui est sur le disque; on cha On monte une page physique depuis le disque (page

Granularité bcp plus fine que le swapping de pri
 Chargement et déchargement de morceaux de

Mém virtuelle

Les pages virtuelles de l'esp mém utilisable d'un pro
Code + données + pile + tas + bibliothèques + ...

Mam reinidaria

Les pages d'un pro physiquement en RAM

Transparent pour les pro, géré par le noyau

Habituellement, une page physique est com
associée à plas pages logiques

Curetto qui peut Phro d'

ition st-ce qui peut être plus grand que la taill La taille de la mém virtuelle d'un orc :

La taille de la mém virtuelle d'un prc : Ou.
La taille de la mém résidente d'un prc : Noi
La somme des tailles de la mém résidente
La somme des tailles de la mém résidente

nanon conee mmu (rappeu)
La table des pages (MMU) indique seulement
Si une page logique existe
Et si oui : où (quelle page physique) et avec quels droi

ration d'une page sur disoue

Quant le SE migre une page

Il marque que la page est en swap (et où)

Ça ne rentre pas dans la table des pages

Le sya a ses propos struct de données

Il met à jour la table des pages pour invalider al

met à jour la table des pages pour invalider al

colt copie sur disoque et ma (et a label des page

sés du cre à une page virtuelle en RAM

MILI stakti conceinent aut fortionius en part inh

MILI stakti conceinent aut fortionius en part inh

MMU traduit correctement adr logique en adr physique
 Le CPU travaille normalement (rien de spécial)

Une faute CPU est lancée

Si le CPU accède à une page logique absente

Si le CPU accède à une page logique avec les mauvais dr

<u>Até MMU : on ne change rien</u>
• Pas besoin de changer de pro

Alias: swap
 Fich ou partition dédiés
 Utilisée comme mém sup
 Accès lent, donc à utiliser

reats sunalmas poss, et configurables

x86-64: souvent 48bits d'adressage sur 4 niveaux (mode long 4k)

57bits d'adressage sur 5 niveaux chez de récents pro Intel
Taille des pages variable

mas peuvent cohabiter en mm temps

Scp de détails tech (et historiques) Plars schémas poss, et configurables

Plsrs tailles et schémas x86-64: 4ko, 2Mo, 1Go s fctionnalités

Des esude abtied d'indirection ne passe pas Stat d'actessage lorgiques
 Stats de numéro de page logiques
 12 bits de numéro de page logique
 12 bits de déclariger
 8 octets par entrée de la table
 Adr de base de la page physique
 Madactomètes (droits de la page, etc.)
 Stat réserve de pages
 Tallance du la baté de pages
 Tallance du la baté de pages
 STAGO par table =
 STAGO par table =
 STAGO par table =

Défaut maieur de page

L'adr virtuelle est valide

Mais la page n'est pas en mém : elle est sur disque

I faut faire des entrées sorties pour la récupérer

Métrique % de time (1)

Métrique % de time (1) La mêm des pro est bop plus riche que ce que le pro offre La table des pages du MMU est trop bas niveau, trop spéc tron limitée Défaut mineur de page

■ L'adri virtuelle est valide

Or page physique est en mém (cache ou chance)

Mais n'est pas associée dans la table des pages

Mérique %R (recoverable) de timel (1)

→ le sys met juste à jour la table des pages (peu couth Des struct de données additionnelles sont nécessaires Le sys gêre des zones virtuelles regroupant Plsrs pages: les ligne de pman(1)

Prob bien étudié et bien généralisable (swap, cache...

Ou est la table ?

Registres ? Non, la table est trop grande !
Un gros bloc en mém ? Où est ce bloc ?
Soliution habitualle
Registre privilègié pour l'adr de la table (CR3 chez x86)
Tables d'indifection en RAM

Objectif

Trouver à chq demande quelle page physique utilise

Determiner quelle page migrer quand la mêm est ple

Minimiser le nb de défauts de pages (et de migration
idées de base : quelles pages migrer? uestions • L'adr dans CR3 est-elle logique ou physique ? C'est une

Idées de base : quelles pages migrer?

Idéel : Les pages non utilisées dans un futur proche
Approximation : Les pages non utilisées récemment
Approximation pire : Les pages anciennement aloué
Algo natif : file Un pro peut-il modifier la valeur du registre CR3 ? Non, slm l'OS. Un pro peut-il modifier la table des pages ? Non, slm l'OS. Soldeste maximals

Permit de la morceaux de mais est palgar (min. tall 10

Soldeste maximals

Permit de la morceaux de máin

Permit d'ulisien tout l'esp d'adressage (ou preque)

Indipendir d'un bet de l'ulisiation des morceaux

Possibilité dans de de la fille (et et esp pre
Possibilité dans de de la fille (et et esp pre
Pas fordiment avec la min agel loque

Pas fordim

Principe

Les pages vieilles migrent en swap

Exercice: Séq: 1, 2, 3, 4, 1, 2, 5, 1, 2, 3, 4, 5 avec 3 pages physiques

112

Attrape l'interruption matérielle Détermine que la page virtuelle est invalide Envoie SIGSEV au pro pro est terminé (ou gère le signal) coût: une vérification en plus

Recommence l'instruction
 Qui réussit (cette fois)

E
Attrape l'interruption matérielle
Détermine que la page virtuelle est en fait en swap
Lance le chargement dans une page physique
(et éventuellement la migration d'une autre page si pas de place
Passe le pro à bloqué (et appelle l'ordomaniceur)
of la chargement est fin. la SE:

Pomaria e Baside vicensis Medicasal

Ance plus de pages physiques (flux de RAM)

Lenh de fauta en decioral pas richina (flux de RAM)

Lenh de fauta en decioral pas richina (flux de RAM)

Lenh de fauta en decioral pas richina (flux de RAM)

Lenh de fauta (flux de la contre de harresi

Dares certaines situations, len de fauta guerra de la contre de harresi

Comme FFO, mais un bi richique si 1y a su utiliario de la contre de harresi

Lenh Limitarque les pages difficies (MAM). 1 losque dépit

Si son bit = 1, on le passe à dission on migre la page en si

Si son bit = 1, on le passe à dission on migre la page en si

Si son bit = 1, on le passe à dission on migre la page en si

Si son bit = 1, on le passe à l'active de la contre d

MM 加加 12 5 13 5 6 6 7

TP

FB SIO FR DET

--- 621 – MÉMOIRE VIRTUELLE AVANCÉE

Aller plus loin?

Allouer, initialiser, charger, copier la mém efficacement.

Offir des services aux pro
Optimisation

Optimisation

Associer pages logiques et physiques pai

Mise à zéro paresseuse de la mém

Partager les pages à outrance

Charger les fichiers paresseusement

→ De façon transparente pour les pro

Services aux pro

Allocation de mém

Allocation de mém

Allocation de mém
 Projection de fichiers en mém (mmap)
 Communication par mém partagée
 Configuration de politiques (et d'heuris)

Ordinaration de politiques (et if heuristiques)
 Alias : région mêm vitains—
 Alias : région mêm vitains—
 Les défaits du firet à mesure
 Les départes de l'account de processer (et MMU)
 Eliptro de l'account de processer (et MMU)
 Les départes de passe de saison de gestion de d'impérimentation
 Le morceaux cohérents
 Correspondet au ligites de prinapt () et de liptro-PIDITE de l'account de passe de l'account de passe de l'account de passe de l'account de

Swap + allocation paress

Mém virtuelle

Mém virtuelle
Les pages virtuelles dans l'espace d'adressage
Colonne VIST de top(1)
Colonne VIRT de top(1)
VmSze, etc. de /procIPID/status
Colonne Size de pmap(1)

Colonne Size de pmap(1) s résidente les pages physiques réellement en RAM Colonne RSS et %MEM de ps(1) Colonne RSS et %MEM de top(1) VmRSS, etc. de jrroof/Pillstatus (Linux) Colonne RSS et gemap(1) Note: rss = resident set size

Faire la copie paresseuse de pages mém
 Exemple d'utilité : rendre fork(2) très efficace

Stratégie

Lors d'une demande de copie de page

On copie rien, on utilise juste deux fois la mm page physique

On ne fait une copie de la page seulement au premier accès en écr

Mise en o euvre COY

Lors d'une copie, on met a jour la table des pages

Tout se passe normalement
 → Cout: 0
Lors d'un accès en écr à la page logique.

Qui recommence l'instruction (et réussit cere rois)

"Ras besoin de passer à bloque"; c'est un défait de page mineur
Cout: copie d'une seule page et maj de la table des pages

strong

l'origination de la table des pages et l'origination de la table des pages

strong

l'origination de la table des pages en lect seule ? C'es

Comment distinguer un COU d'une virale page en lect seule ? C'es

Zone partagée (shared)

• Diff pro utilisent les mms pages partagées
• Si la zone est écrivable, les modif sont vues par tous

Dit pro cussion was more specification.
 Si a zone set servinde, les modifications par bous
 Draccole partiagle peut des utilisée par un seul pro
 Dit pro cultient des pages privise avancelles et des pages
 partiagées communes (en lect seule)
 Duand une page privise est dorite. Les modificant vues que pair le pro
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite : copie sur der
 Duand une page commune set dorite

Partage des pages sous
pmac(1) et (progPiDimaps affiche s pour les zones partagées
(ou p) pour les zones privées
Colonne SHR (shared) de log (1): somme des taille des pages
partagées
Colonne Pss (proportional set size) de pmap(1): chaque page
divisée par le nh d'users